Big Data Architecture & Data Integration: ChuvaRota

Global Solution 2026.2 · Engenharia de Software · 4º ano

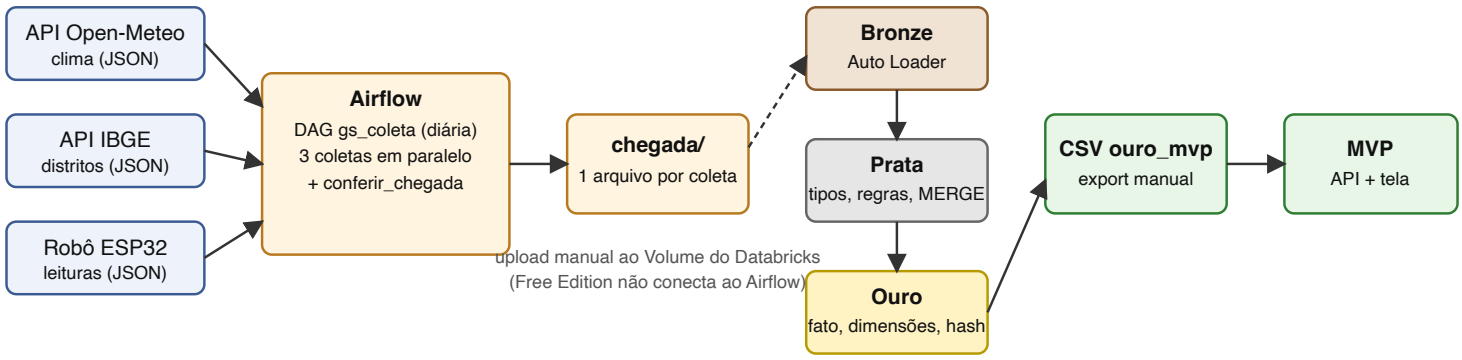
1. Integrantes

Vinicius Barros, RM 97824

2. O produto e as perguntas que o MVP responde

ChuvaRota mostra o risco de chuva por região de São Paulo para quem se desloca a pé ou de ônibus. As perguntas que a parte de dados responde: onde mais choveu, onde houve horas de risco alto, em que horário chove mais e se o sensor do robô confirma o risco previsto.

3. Diagrama do fluxo de dados



4. Fontes

Fonte	Origem	Formato	Frequência
Clima por hora	Open-Meteo (API de arquivo)	JSON, 1 arquivo por região e dia	diária
Distritos de SP	IBGE (API de localidades)	JSON, 1 arquivo por dia	diária
Leituras do robô	gerada em código (o robô ainda não envia)	JSON, 1 arquivo por dia	diária

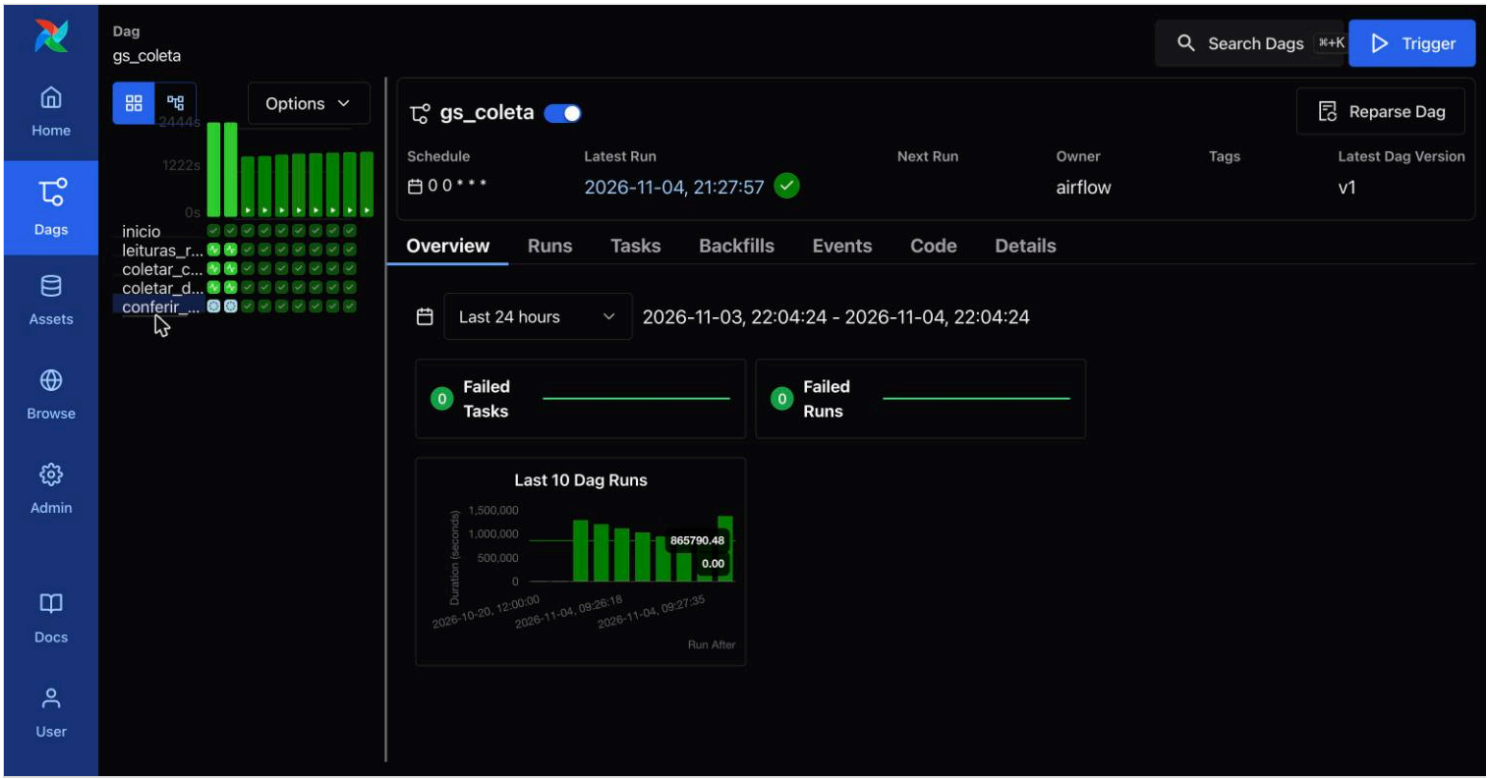
5. Requisitos 01 a 09

01 Fontes de dados

Duas fontes reais e públicas: a API de arquivo do Open-Meteo (chuva por hora, uma região por arquivo) e a API de localidades do IBGE (distritos de São Paulo). Uma terceira, as leituras do robô, é gerada por uma função em `dags/coleta.py`, porque o robô ainda não envia dados em campo.

02 DAG de coleta agendada

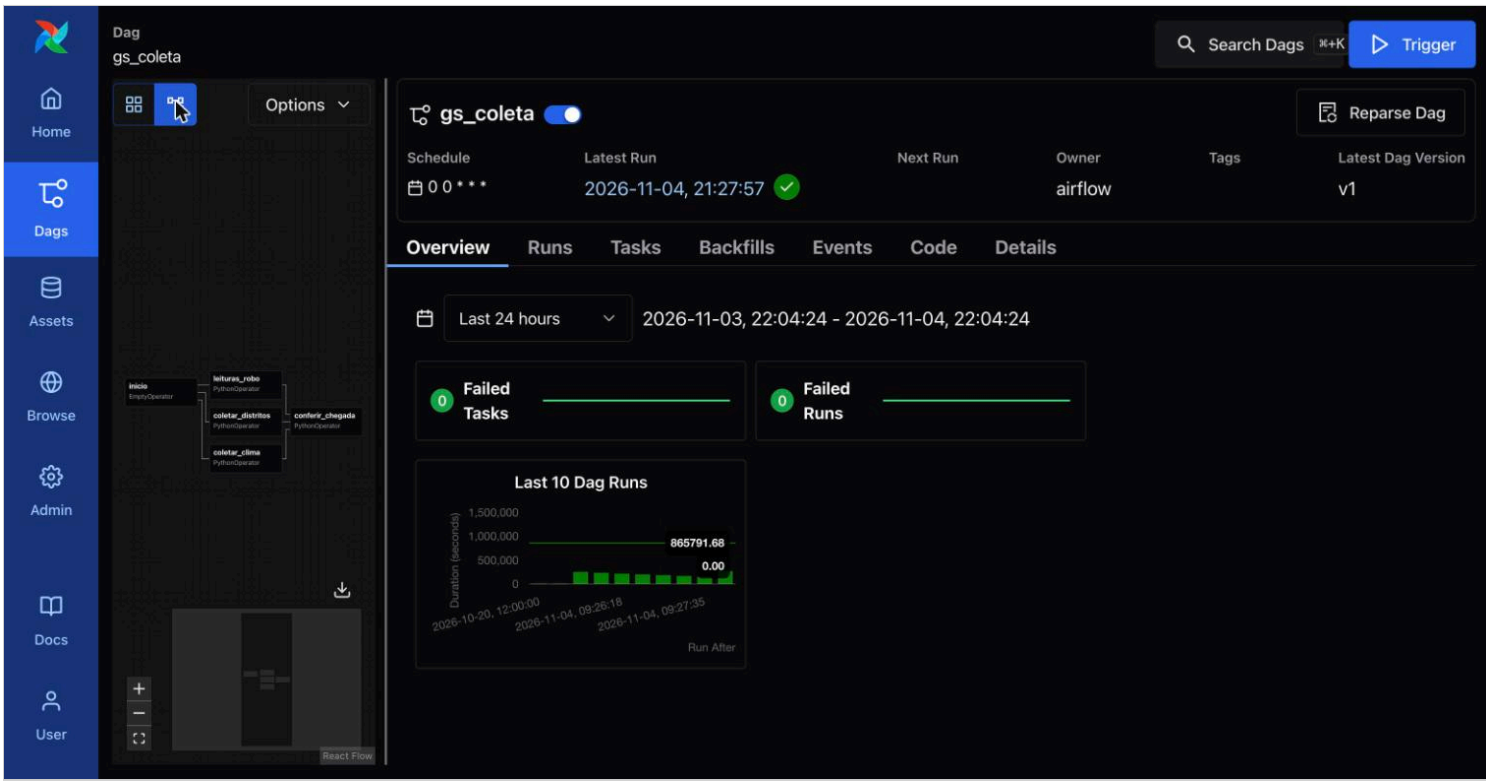
A DAG `gs_coleta` roda todo dia e grava um arquivo por coleta na pasta `chegada/`, com a data no nome (ex.: `clima_mooca_2026-10-25.json`).



Airflow, visão Grid: execuções concluídas.

03 Paralelismo e verificação

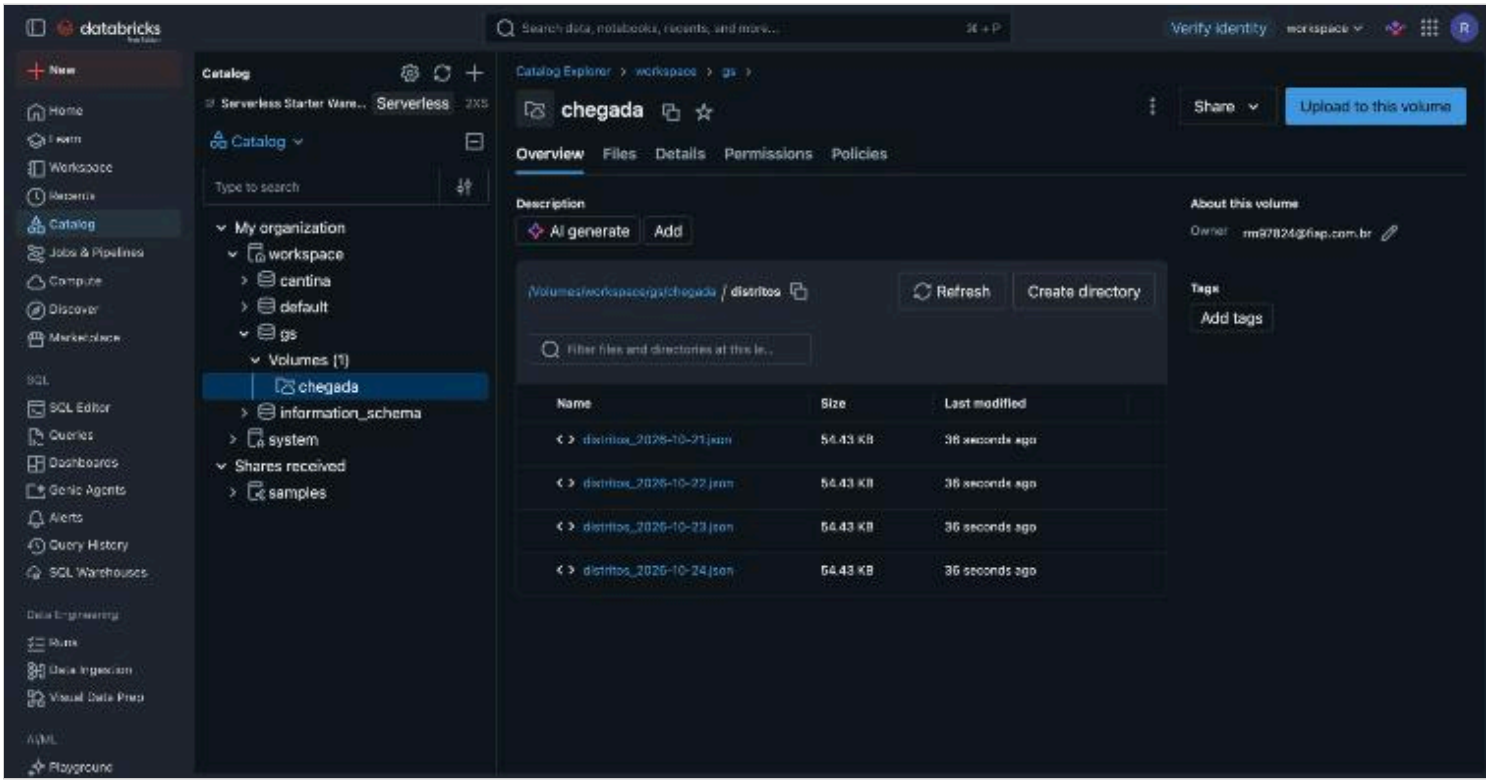
As tarefas `coletar_clima`, `coletar_distritos` e `leituras_robo` rodam em paralelo e a tarefa `conferir_chegada` falha se algum arquivo estiver ausente ou vazio. As APIs usadas não pedem chave; o caminho da pasta vem de uma Variable do Airflow, não do código.



Airflow, visão Graph.

04 Dois lotes no Volume

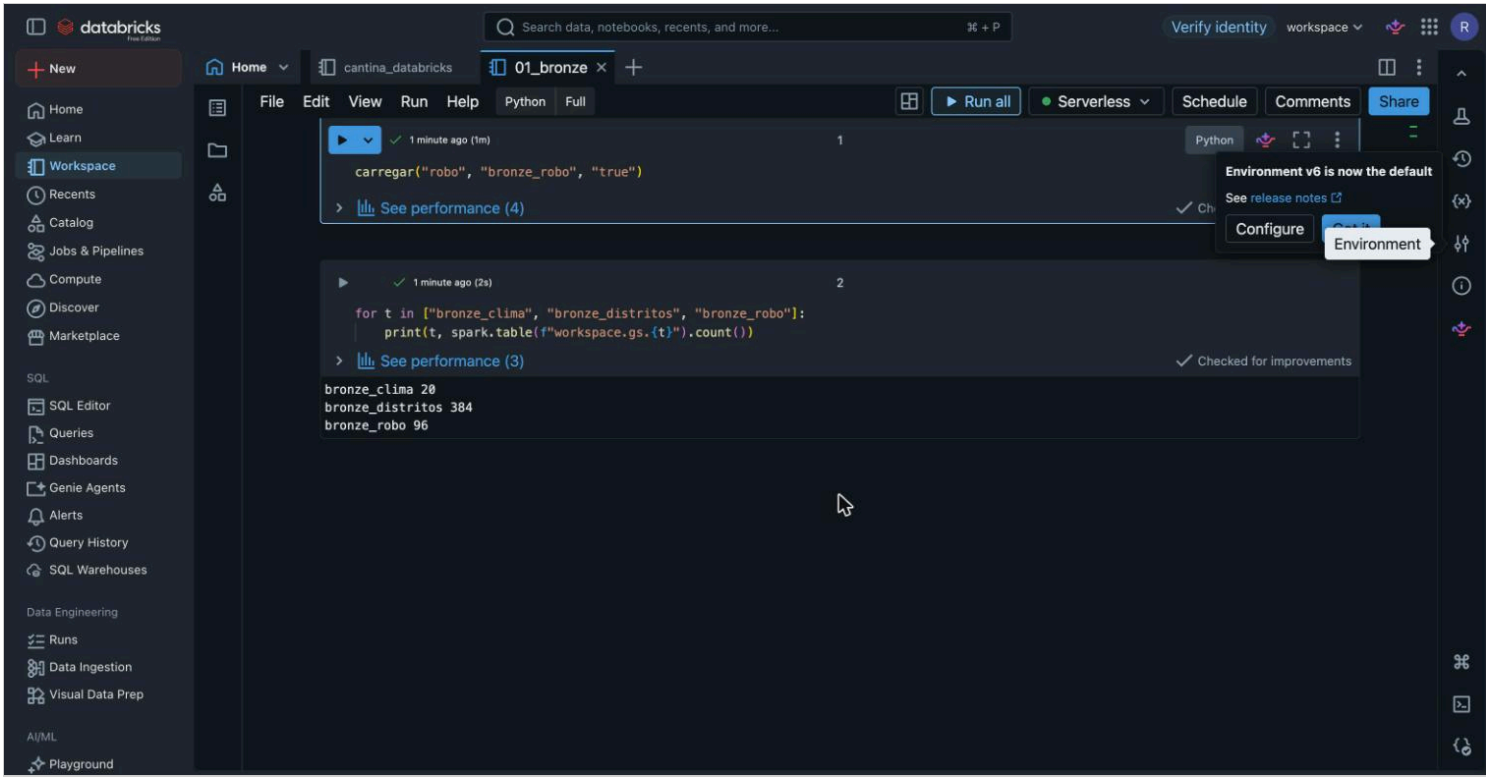
O lote 1 tem os dias 21 a 24/10 e o lote 2 os dias 25 a 27/10. Os dois foram enviados pela interface ao Volume `workspace.gs.chegada`.



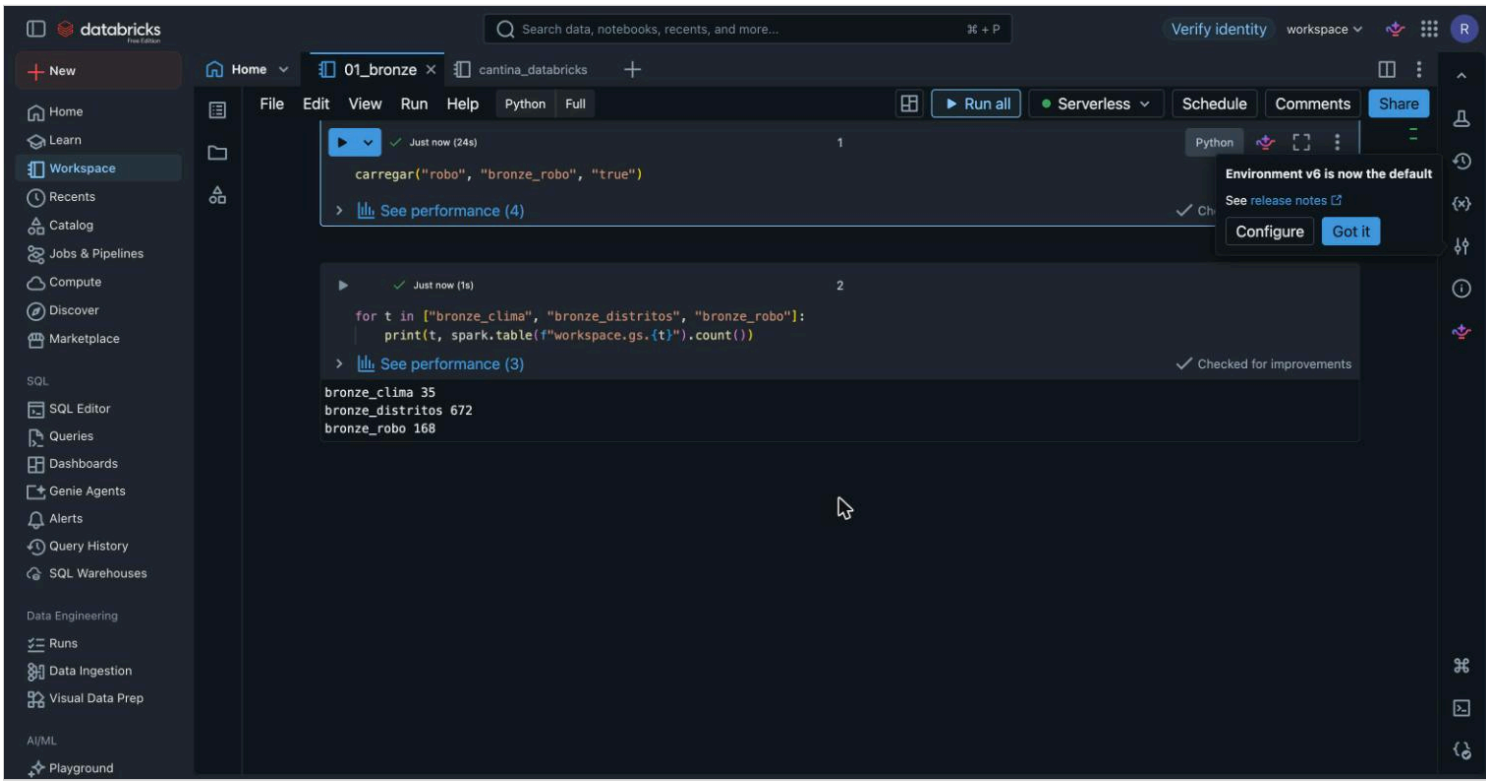
Volume com os arquivos de distritos do lote 1.

05 Bronze incremental

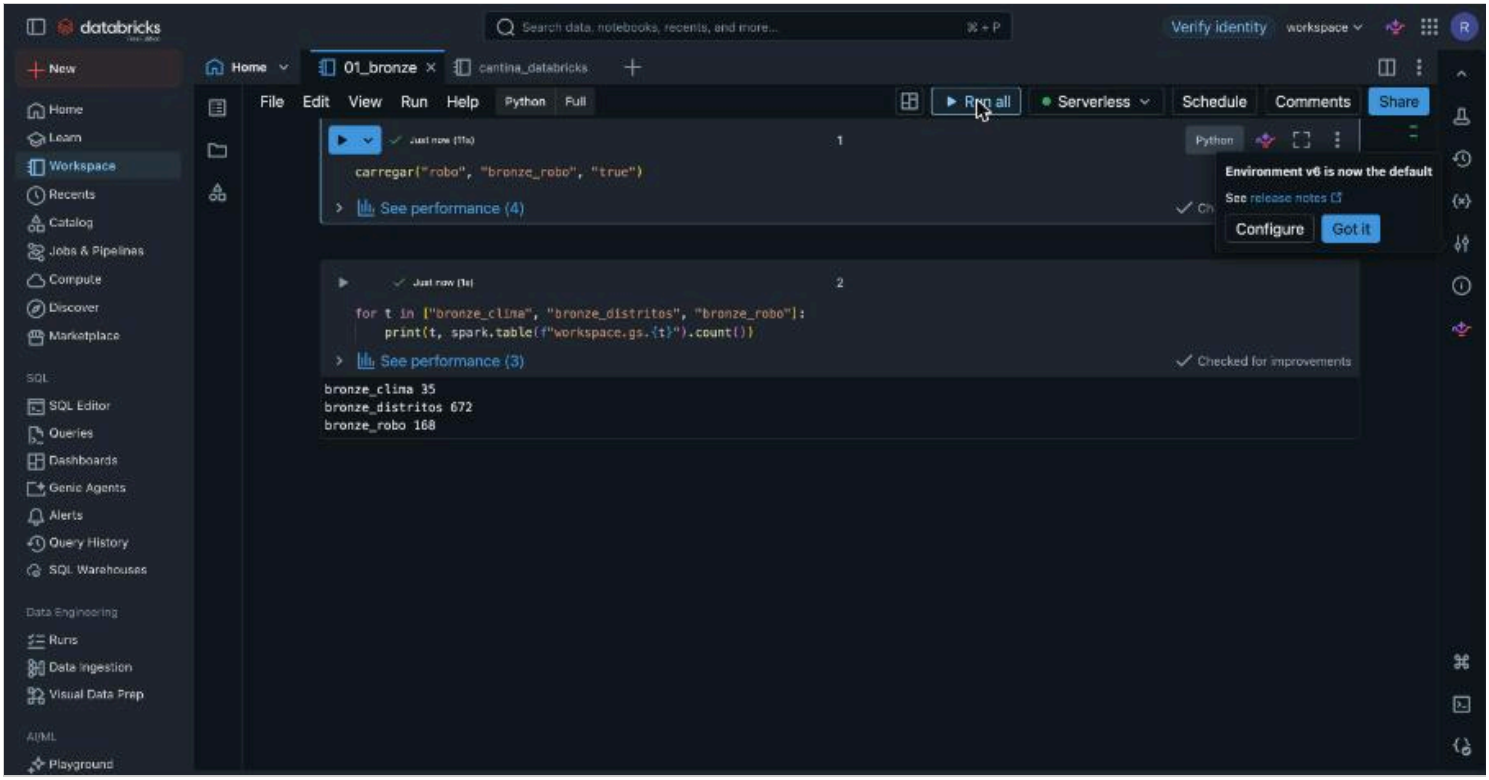
A Bronze usa Auto Loader com checkpoint. Depois do lote 1 a tabela tinha 20 / 384 / 96 linhas (clima / distritos / robô). Depois do lote 2, 35 / 672 / 168: só entraram os arquivos novos. Rodando de novo sem arquivo novo, nada mudou.



Contagens após o lote 1.



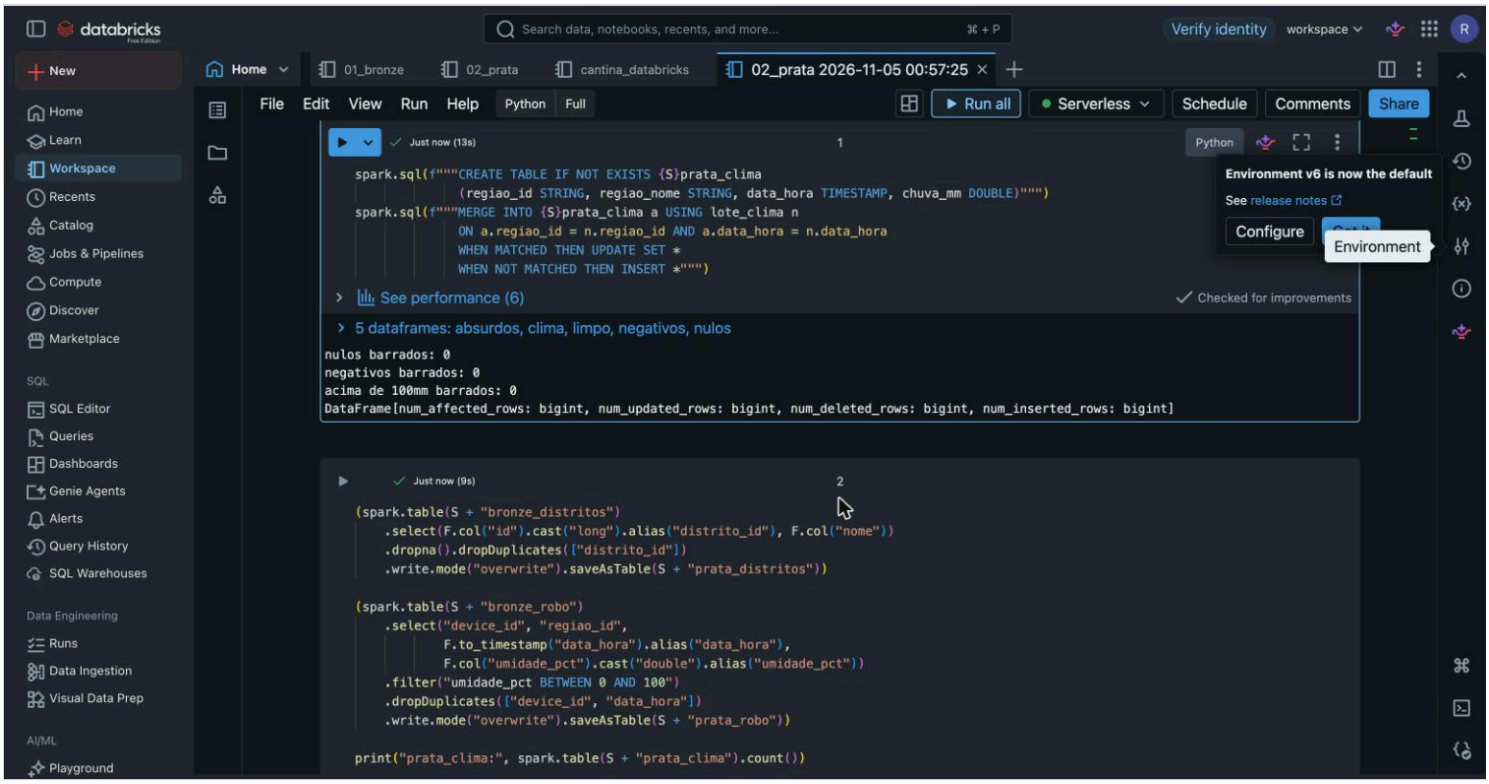
Contagens após o lote 2.



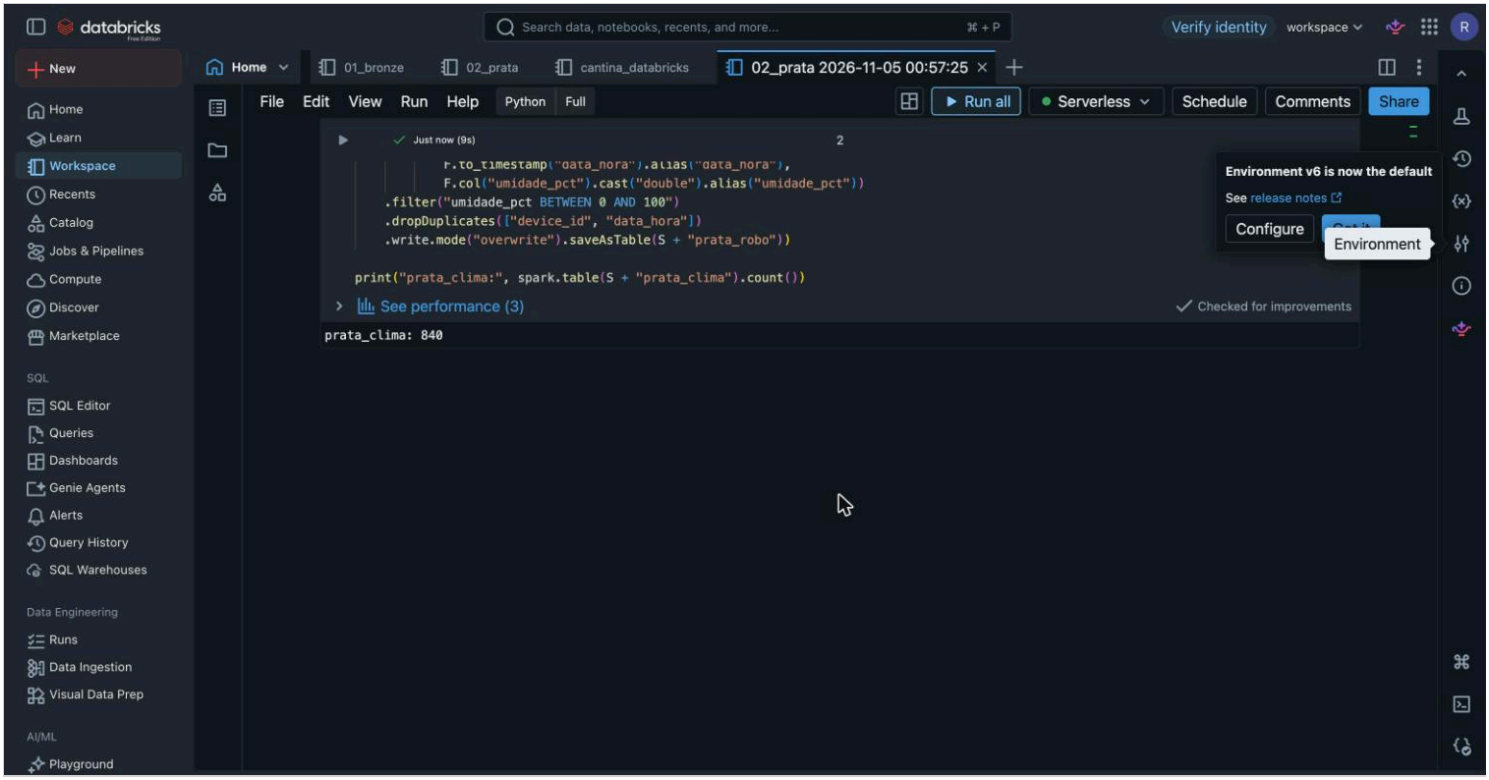
Contagens após rodar de novo, sem arquivo novo.

06 Prata

O campo `hourly` chega como texto e é convertido com `from_json`; depois as listas paralelas viram uma linha por hora. Há três regras de qualidade, com o total barrado por cada uma: nulos (0), negativos (0) e acima de 100 mm (0). O dado real veio limpo, então nenhuma linha foi barrada. O `MERGE` pela chave região + hora gerou 840 linhas (35 arquivos × 24 horas).



Regras de qualidade e MERGE.



Total de linhas da prata_clima.

07 Ouro

A tabela fato é `fato_chuva` (chuva por hora, soma de 3 horas e risco). As dimensões são `dim_regiao` e `dim_tempo`. Também há `fato_leitura_robo` e a tabela de resumo `ouro_mvp`. As 5 consultas estão no fim deste relatório.

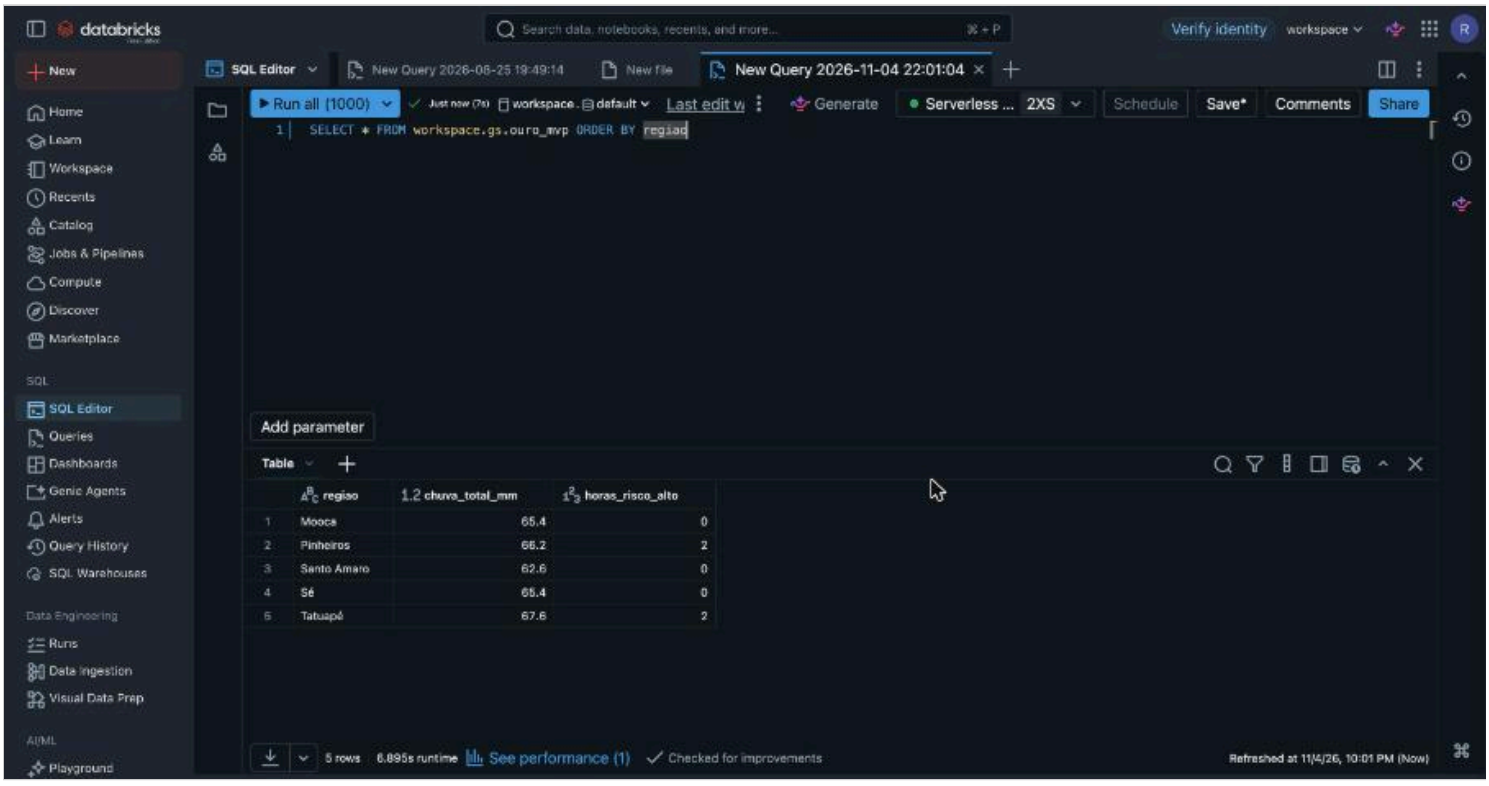


Tabela ouro_mvp.

08 LGPD e uso pelo MVP

Não há dado pessoal nas fontes. O único identificador é o `device_id` do robô, que na Ouro só aparece como hash SHA-256 (`device_hash`). O MVP usa a tabela `ouro_mvp`: o CSV exportado fica em `mvp/data/ouro_resumo.csv` e a rota `/historico` o entrega à tela inicial.



Tela do MVP com a tabela do histórico.

09 Repositório e README

Código, notebooks, amostras e instruções em https://github.com/ViniciusBarrosFiap/chuvarota (pasta `dados/`).

6. Contagens da Bronze

Momento	clima	distritos	robô
Depois do lote 1	20	384	96
Depois do lote 2	35	672	168
Segunda execução, sem arquivo novo	35	672	168

7. As 5 consultas SQL

1. Quais regiões mais choveram?

Table

	nome	1.2 mm
1	Tatuapé	67.6
2	Pinheiros	66.2
3	Mooca	65.4
4	Sé	65.4
5	Santo Amaro	62.6

Tatuapé teve 67,6 mm, Pinheiros 66,2, Mooca e Sé 65,4 e Santo Amaro 62,6. A diferença entre a maior e a menor é de cerca de 5 mm: a chuva ficou bem distribuída pela cidade nesse período.

2. Quantas horas de risco alto por região?

Table

	nome	horas_alto
1	Pinheiros	2
2	Tatuapé	2

Só Pinheiros e Tatuapé passaram do limite de 15 mm em 3 horas, com 2 horas cada. As outras três regiões não tiveram nenhuma.

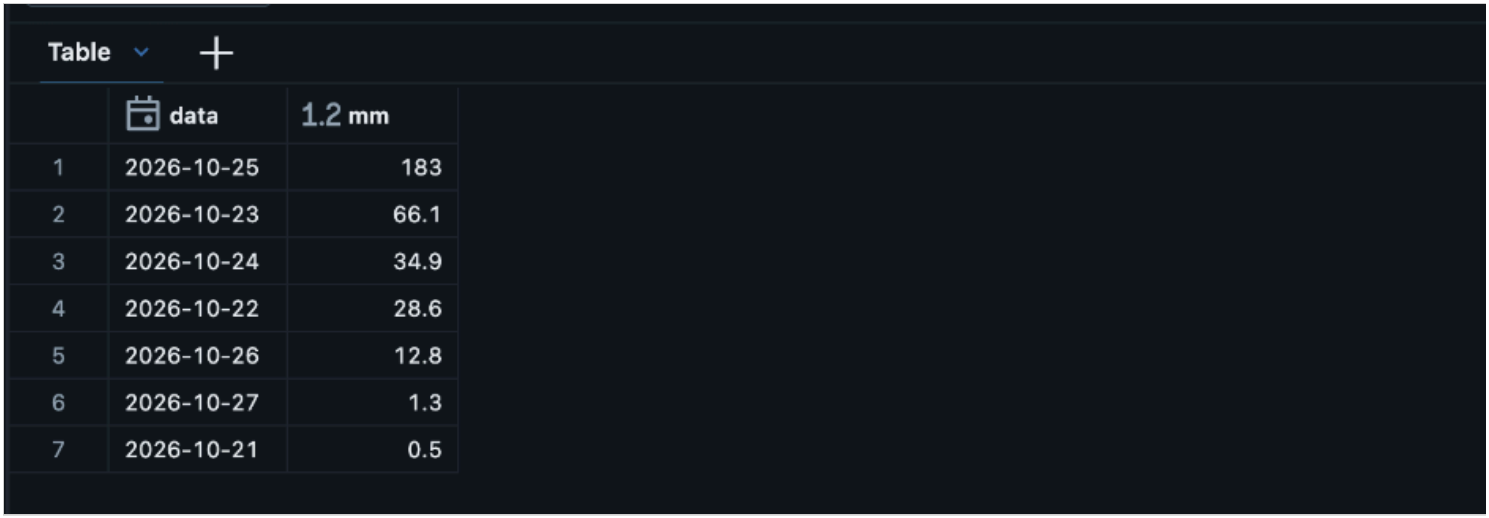
3. Em que horário chove mais?

Table

	hora	media_mm
1	1	1.14
2	0	1.13
3	7	0.94
4	8	0.73
5	3	0.66

As maiores médias são à 1h (1,14 mm) e à meia-noite (1,13 mm), depois 7h (0,94). A chuva do período se concentrou na madrugada e de manhã cedo.

4. Qual dia teve mais chuva?

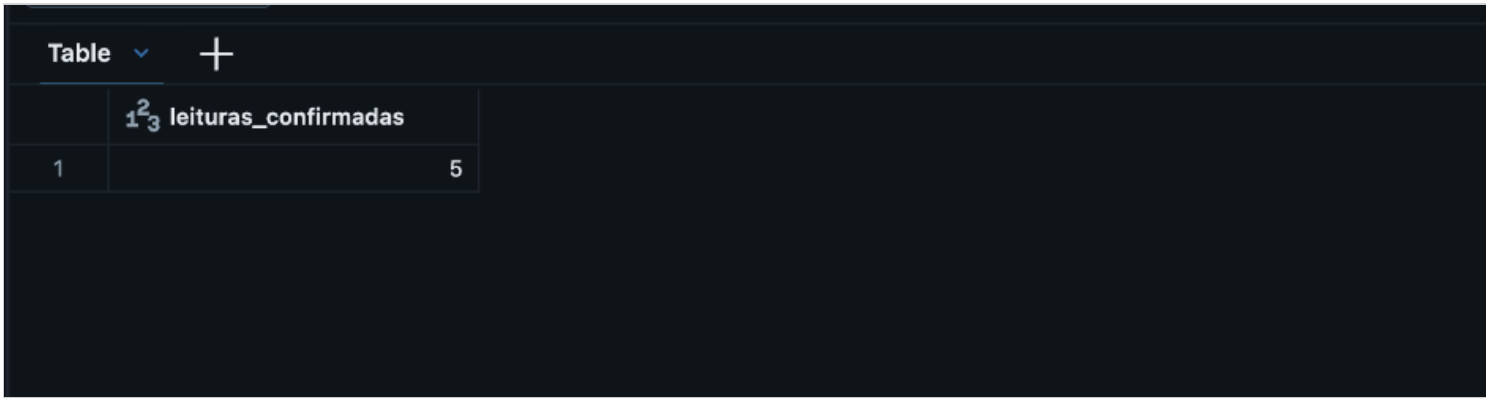


Table

	data	1.2 mm
1	2026-10-25	183
2	2026-10-23	66.1
3	2026-10-24	34.9
4	2026-10-22	28.6
5	2026-10-26	12.8
6	2026-10-27	1.3
7	2026-10-21	0.5

O dia 25/10 teve 183 mm somando as cinco regiões, bem acima dos outros. Os dias 21 e 27/10 ficaram quase secos (0,5 e 1,3 mm).

5. Impacto: leituras do robô em horas de risco



Table

	leituras_confirmadas
1	5

Foram 5 leituras com umidade acima de 60% em horas de risco médio ou alto. Como as leituras ainda são geradas, o número só prova que o cruzamento funciona. Com o ESP32 mandando dados reais, a mesma consulta passa a medir quantos alertas o robô confirmou no local.

8. Conclusão técnica

A pipeline coleta, trata em três camadas e entrega ao MVP uma tabela de resumo, sem duplicar dados ao rodar de novo. Dois limites: o envio dos arquivos ao Databricks é manual, porque a edição gratuita não se conecta ao Airflow, e as regras de qualidade não barraram nada porque o dado real veio limpo. Código, notebooks e passo a passo: https://github.com/ViniciusBarrosFiap/chuvarota.